
Анализ и прогнозирование мошеннических транзакций по кредитным картам

Работу выполнили:


Платонов Максим

Виталий Ким

Дугин Иван

Феськов Алексей

Раздел 1: EDA (Exploratory Data Analysis)

A close-up, low-angle shot of a gold-colored credit card. The card is slightly curved, and the embossed numbers and a chip are visible. The lighting is warm and golden, creating a sense of luxury and value. The background is blurred, focusing attention on the card's details.

Обзор выбранного набора данных

- Набор данных содержит симулированные транзакции кредитных карт за период с января 2019 по декабрь 2020 года.
- Обучающая выборка (Train): 1.296.675 строк
- Тестовая выборка (Test): 555.719 строк




Основные признаки:

- **cc_num:** номер кредитки
- **merchant:** продавец (магазин)
- **category:** категория услуги/транзакции
- **amt:** сумма транзакции
- **lat/long:** коорд. совершения платежа
- **unix_time:** время совершения операции

Дисбаланс классов

В `df_train` наблюдается выраженный дисбаланс классов: подавляющее большинство операций - легитимные (класс 0) - 1 289 169 транзакций (99.42%), тогда как мошеннических операций (класс 1) всего 7 506 (0.58%). Из-за такого перекоса ассурасу будет малоинформативной, поэтому при моделировании стоит ориентироваться на метрики для редкого класса (PR-AUC/Recall/F1)



Выделяющиеся месяца



До 2019-03: 0.999% (n=102,391, frauds=1,023)
С 2019-03: 0.543% (n=1,194,284, frauds=6,483)



Заметно, что в январе и феврале 2019 года уровень фрода был в два раза выше, чем в любые другие месяцы, при этом объем транзакций январе и феврале 2020 не менялся (~50к/месяц).

Разница между периодами была подтверждена тестом*, в связи с этим был сделан вывод о том, что эти данные не являются шумом, а такая картина похожа на смену режима (policy/concept drift): либо действительно изменились антифрод-правила/процессы разметки, либо существенно поменялся состав транзакций (категории, часы, география) после 2019-03.

В дальнейшем этот вывод был использован для создания флага

*Разница между периодами подтверждается тестом разницы долей: до 2019-03 - 0.999% (n=102,391) против с 2019-03 - 0.543% (n=1,194,284), z=18.47, p-value практически нулевой


Распределение сумм транзакций



Сумма транзакций является одним из сильнейших признаков для определения класса транзакции.

- У легитимных операций (0) распределение смещено в сторону более крупных сумм и имеет выраженные пики около 600–1000, что похоже на “ типовые ” суммы.
- У мошеннических операций (1) распределение в среднем левее - основной массив лежит примерно в районе $\log_{10}(\text{amt}+1) \approx 1.7\text{--}2.1$ (то есть около 50–125), при этом есть заметный “хвост” к совсем малым суммам.


Временные паттерны



На графике видно, что распределение количества транзакций по часам сильно отличается для чистых и мошеннических операций. Для Clean поток относительно ровный в ночные/утренние часы и заметно возрастает днём и вечером (примерно с 12:00 до 23:00) - это похоже на обычное поведение пользователей, когда активность выше во второй половине дня. Для Fraud картина иная: основные всплески приходятся на поздний вечер, особенно на 22:00-23:00, тогда как в большинстве остальных часов число фрод-транзакций значительно ниже.



При этом не замечено особой связи типа транзакции с днем недели.

Группы категорий по рискам




- **Shopping Net** – наивысший fraud rate: **1.76%**. Онлайн-покупки наиболее фродовые.
- **Misc Net** – доля фрода: **1.45%**. Прочие онлайн-сервисы показывают высокую рисковость.
- **Grocery POS** – доля фрода: **1.41%**. Офлайн продукты – единственная крупная рисковая категория в POS (оффлайн)

Демографические факторы



- Для оценки значимости различий использован тест **Хи-квадрат Пирсона**. **P-value < 0.001** указывает на наличие статистически значимой связи между полом и вероятностью фрода, однако размер эффекта (V Крамера) крайне мал.
- По графику возраста видно, что fraud-rate не монотонный, но можно заметить тренд, что пожилые группы находятся в зоне повышенного риска.

Раздел 2: Baseline

The background of the slide is a complex, abstract digital pattern. It features numerous concentric circles and rings, some of which are composed of small, square or rectangular blocks, creating a sense of depth and movement. The color palette is primarily dark blue and black, with lighter blue and white highlights that suggest a futuristic or technological theme. The overall effect is one of a high-tech, data-driven environment.

Метрики CatBoost по Baseline

Метрика	Значение
PR-AUC	0.91511
ROC-AUC	0.99690
Precision	0.9410
F1-Score	0.8635
Recall	0.7978


На валидации (259 335 наблюдений, fraud rate 0.593%) модель показывает очень высокое качество ранжирования: PR-AUC = 0.915 (ключевая метрика для редкого класса при среднем `is_fraud` ~0.005789) и ROC-AUC = 0.9969. При стандартном пороге 0.5 получаем Precision=0.963 и Recall=0.747 (мало ложных срабатываний, но часть фрода пропускаем); при подборе порога под максимум F1 качество по балансу precision/recall улучшается (F1=0.8635, Recall=0.7978).

Такие хорошие значения получились, потому что CatBoost "из коробки" работает хорошо.


Аномалии и генерация на их основе

При анализе по iqr и z-score у city_pop выявлены наибольшие хвосты, amt был тоже кандидат выбросы. При подробном изучении графиком стало ясно – все выбросы удалять нельзя, так как это приведет к потере данных и смещению.

Высокие amt – крупные покупки, а хвосты city_pop – различие мегаполисов и малых поселений.



Feature Flag



Доли срабатываний флагов (train), %:

0	
an_city_pop_iqr_hi	18.715
an_amt_iqr_hi	5.189
an_amt_z_gt_4_0	0.008
an_amt_iqr_lo	0.000
an_city_pop_iqr_lo	0.000
an_city_pop_z_gt_4_0	0.000

На основе выделенных аномалий были созданы флаги: `an_amt_iqr_hi`, `an_city_pop_iqr_hi`, `an_log10_amt`, агрегат `an_count_flags`

Большинство строк не имеет ни одного флага. Основными аномалиями по iqr стал высокий `city_pop` и `amt`.

Флаг аномальной суммы (`an_amt_iqr_hi`) оказалось наиболее информативным при его срабатывании `fraud rate` 8.48% при среднем по датасету 0.579%.

Очень хороший итоговый агрегатный признак - `an_count_flags`: при 0 флагах `fraud rate` 0.148% (ниже среднего), при 1 флаге 1.78% (lift ~3.1x), при 2 флагах 6.59% (lift ~11.4x). Это удобный "risk counter": чем больше аномальных характеристик у транзакции, тем выше вероятность фрода.

Генерация признаков

Аномальный период времени

is_pre_2019_03 — флаг периода до марта 2019

До 2019-03 fraud rate $\approx 0.999\%$, после — $\approx 0.543\%$ (z-тест, $p \approx 0$)

Сдвиг не объясняется изменением микса категорий/часов → это смена режима разметки/правил, важная для валидации

Праздники

is_holiday, is_day_before_holiday, is_day_after_holiday – флаги по празднику, дню до праздника, дню после праздника

Время суток и недели

is_weekend, is_night (0–3 ч), is_late_evening (22–23 ч)

Сводный is_high_risk_time - объединяет ночь и поздний вечер, где концентрируется фрод

География и сезонность

us_region - 4 региона по штатам (запад, восток, север и юг);

year_month - месяц как категория


Гео-соседи

cust_nn1_km / merch_nn1_km - расстояние до ближайшей другой точки


cust_loc_txn_cnt / merch_loc_txn_cnt - плотность транзакций в координате

Вывод: временной контекст (режим + час + праздники) и гео-плотность дают модели сигналы, которых нет в «сырых» полях; is_high_risk_time далее войдёт в топ важности.



Основные признаки





После удаления ID/PII (имя, фамилия и тд), отобрали топ-25 лучших признаков и из них оставили 15 наиболее важных по embedded importance: category, amt, is_high_risk_time, city, hour, dob, job, gender, cust_loc_txn_cnt, is_late_evening, year_month, long, city_pop, merchant, age.

A microscopic image showing a dense, regular array of small, circular, dark-colored features (possibly pores or cells) on a lighter, textured background. The features are arranged in a grid-like pattern, with some larger, more irregular features interspersed. The overall appearance is that of a biological or synthetic material with a high degree of organization.

Раздел 3: Интерпретация признаков







SHAP CatBoost



SHAP LogReg

LIME CatBoost





LIME LogReg

Сравнение CatBoost и LogReg

Вывод: топ-5 признаков обеих моделей пересекаются на 4 из 5 позиций (amt, category, is_high_risk_time, city/hour). Это подтверждает, что данные признаки несут реальный сигнал, а не артефакт конкретного алгоритма.





Признак	SHAP CatBoost	SHAP LogReg	LIME CatBoost	Вывод
amt	#2 (1.59)	#5 (0.88)	#1 (0.40)	совпадает
category	#1 (1.68)	#4 (1.09)	#4 (0.27)	совпадает
is_high_risk_time	#3 (0.94)	#2 (1.38)	#5 (0.06)	совпадает
city	#4 (0.26)	#2 (1.49)	#2–3 (0.37)	совпадает
hour	#6 (0.20)	#6 (0.65)	#4 (0.07)	совпадает
merchant	вне топ-10	#4 (0.96)	#5–8 (0.21)	частично

Локальная интерпретация


Определяющие признаки: сравнение методов

Признак	SHAP CatBoost	SHAP LogReg	LIME CatBoost
amt	+4.70 (#2)	-5.50 (#2)	amt > 175.18 (#1)
category	+8.01 (#1)	-1.96 (#4)	category=11 (#7)
city	+4.68 (#3)	+0.68 (#10)	city=172 (#2)
is_high_risk_time	+1.06 (#5)	+2.26 (#3)	0< <u>is_high</u> ..<=1 (#5)
hour	+0.93 (#6)	-1.03 (#7)	hour > 21 (#4)
job	+1.10 (#4)	вне топ-10	job=89 (#3)
amt_pow_imp	—	+16.99 (#1)	—

amt, category, city и is_high_risk_time присутствуют в топ признаках всех трёх методов — это сильный сигнал их реальной важности для данного конкретного наблюдения



Shapley Flow — все наблюдения



Итоговое сравнение качества моделей

Модель	PR-AUC	ROC-AUC	Статус
CatBoost original (full train)	0.92410	0.99715	baseline
CatBoost clean (SHAP outliers)	0.90874	0.99675	хуже
CatBoost + shap_cluster	0.79388	0.99462	хуже
CV mean: CatBoost	0.98460	0.99800	лучше*
CV mean: LR(SHAP only)	0.97894	0.99748	лучше*
CV mean: LR(SHAP + orig)	0.97931	0.99749	лучше*

SHAP-анализ и Shapley Flow ценны для интерпретации, а не для улучшения метрик. Они подтвердили, что модель правильно опирается на category, amt и время суток, и показали структуру взаимодействий между признаками. Качество оригинальной модели остаётся ориентиром.